

PowerTrustAI

项目学习与面试手册

从概念、代码与真实失败理解本机辅助审核

定向修订 r1 · 原型 v0.1 · 2026-10-04

可回查依据 / 有限修订 / 持久化 / 人工监督

不是工程安全认证；不以测试数量代替语义正确。

阅读约定

版本：本机辅助审核原型 v0.1 的学习手册 r1；修订日期：2026-10-04。代码基线为 3d5e0cd842a1039731aafb209fb5444bd1905622，分支 master。本轮核对 Git 历史仍只有该基线提交，没有基线后的文档提交；旧31页手册与本修订版均属于工作区文档，不能说成已纳入该提交。修订版不改变应用版本或运行协议。

2026-10-04 前轮网络诊断记录为 GitHub HTTPS 连接重置、未推送；这是有日期的历史记录。本轮不访问网络、不调用API，未重新确认网络或远端状态，不能将旧诊断当作永久状态。

边界集中说明：检索排序、结构执行完成、模型支持判断与工程认证是不同层次；标注和反馈仍为AI辅助、用户监督，不是专家金标准。后文仅在各机制涉及具体风险时说明，不以重复免责声明增加篇幅。

面向已经会 Python 基础、开始学习 Agent 工程的读者。本手册先解释为什么需要这些对象和边界，再指出实际代码，最后用真实失败讨论设计的有效范围。阅读时不必从全部历史报告开始；优先读本手册、当前运行说明及核心入口，再沿案例查归档。

“已实现”表示当前代码提供该功能；“离线验证”表示假组件或程序测试验证了相应行为；“真实验证”表示服务经 API 调用了实际模型并保留结果。三者不能互相替代。原型的辅助审核结论不是工程安全认证，也没有经过独立专家金标准证明的准确率。

本手册不包含密钥、令牌、请求头、官方全文、运行数据库或完整真实请求响应。短案例摘录用于解释工程行为，大型归档只给出本机相对索引。旧项目与历史参考 PDF 不作为当前配置证据；本次没有读取旧 PDF 正文。

目录

1. 项目目标、适用范围与学习路线	4
2. 最终架构与一次请求的生命周期	5
3. 四 Agent、主张提取与 Harness	8
4. 知识入库、原文与 PDF 质量边界	9
5. BM25、Dense、RRF 与检索取舍	11
6. 版本、引用、快照与严格类型依据	14
7. 工具、预算、超时和取消	15
8. 有限修订与完整重审	17
9. 本机 API、队列、事务与重启	18
10. Web 界面、来源链接与中文解释	20
11. 一次真实服务修订：逐阶段阅读	21
12. 历史失败：契约修复与语义边界	23
13. 测试、检索指标与监督标注	24
14. 本机运行、排错与交付恢复	26
15. 技术取舍、旧项目迁移和后续微调	28
16. 面试问题、追问和回答证据	30
17. 代码阅读任务与证据索引	34
18. 五段关键代码：输入、输出和异常边界	36

1. 项目目标、适用范围与学习路线

1.1 要解决的具体问题

电力问答中的一句话可能同时包含技术事实、数值换算、适用条件、资料引用和工程建议。自然语言流畅并不代表这些部分都成立。PowerTrustAI 将回答冻结后拆成可审核主张，分别检查证据支持与领域边界，把程序能够确定的规则和工具结果单独保存，最后交给确定性政策决定结束或有限修订。

两个入口复用同一套运行流程：问答模式先生成回答，已有回答模式直接审核用户提供的文本。后者不是重新生成一篇答案再假装在审核原文。两种模式都需要保存实际 `answer_id`、版本及提取结果，保证后续发现指向确切文本。

本机原型适用于学习、概念资料核查和人工辅助复核。已有公开资料的适用地域、发布时间和文件质量影响可用范围。项目没有执行潮流、短路、稳定性或厂站仿真，没有多用户权限系统，也没有公网部署。不存在一个已经验证的“可信总分”。

1.2 四种不同的成功

层次	能够说明什么	不能说明什么
程序测试通过	受测输入下的接口、校验和状态符合断言	未受测场景中的模型理解正确
执行阶段完成	必需调用返回并形成合法阶段对象	每项工程检查都可评估
主张 supported	当前模型判断与绑定依据支持这一主张	全回答安全、资料适用或模型没有漏检
工程安全认证	需要专业流程、工程输入与责任体系	本项目没有提供此能力

例如运行已经 finished，双审阶段也完整，但领域审核因缺少工况或工程输入报告 `not_assessable`，这些状态可以同时成立。反过来，即使若干主张 supported，另一条审核响应结构失败，执行完整性也不能被这些成功条目覆盖。

1.3 推荐学习路线

先读 `backend/assembly.py`，看最终组件如何装配；再读 `harness/runtime.py` 和 `harness/policy.py`，理解控制权；随后读 `core/models.py`，认识回答、主张、发现与依据。接下来沿两个分支阅读：一条进入 `rag/` 学习原文与检索，另一条进入 `agents/` 和 `services/` 学习模型契约及程序校验。

最后阅读应用层的 `backend/service.py`、`backend/store.py` 与 `backend/static/app.js`，把“一个模型调用”放回真实用户操作中。不要先背每个提示词版本；应先知道哪个版本由真实服务显式采用，哪些只是历史兼容代码。


学习目标是能够回答三件事：某条结论究竟来自模型、程序还是人工？它绑定哪个回答版本、哪段证据？失败后服务究竟保存了什么？这比记住测试总数更接近项目的工程价值。

本章依据：`docs/prototype-v0.1.md`、`docs/design-decisions.md`、`backend/assembly.py`、`core/models.py`。当前原型的实际验证分层见第 11、13 章；历史方案的迁移边界见第 15 章。

2. 最终架构与一次请求的生命周期

2.1 模块依赖方向

界面只调用同源 API，不读取 SQLite 或运行文件。API 将经过校验的输入交给 ApplicationService；服务管理运行身份、排队、取消及持久化，并通过 ComponentFactory 装配原有 OfflineHarness。Harness 调用 Agent、ClaimExtractor、Retriever 和工具；底层适配器负责模型协议与调用记录。




这里的 OfflineHarness 名称来自项目的离线工程基础，不表示真实服务仍使用假模型。真实装配向它注入真实适配器、BM25 检索与当前审核组件；演示装配注入 synthetic_fixture 假组件。核心流程和确定性政策没有被前端重新实现。

层	主要职责	应避免承担的职责
Web 页面	收集输入、显示状态与版本、追加意见	决定审核政策、拼接数据库路径
API	鉴权、输入验证、作用域及错误响应	自动调整预算、接受任意文件路径
应用服务	排队、状态管理、运行存储、生命周期	创建另一套模型审核逻辑
Harness	阶段顺序、预算、双审、修订、部分结果	让模型自行决定无限重试
Agent 与服务	生成、提取、审核、修订及契约检查	越过冻结版本或偷换依据
Retriever / Tool / Adapter	原文检索、有限计算、模型请求	将检索相似度当作事实支持

2.2 从 POST 到可恢复结果

用户提交后，服务验证 mode 与字段，生成 run_id 并保存运行。若已有活动任务则进入等待队列；当前基线允许一个活动运行、两个等待位置。提交响应应立即返回身份，浏览器开始 GET 状态，不能因为超时再自动 POST 一遍。

运行开始时记录实际装配与预算。问答模式生成初稿后冻结；已有回答模式直接建立初稿。随后提取主张、独立双审、程序检查、政策决定；可能进入一次 Revision，再完整重提取和双重审。每次有效检查点保存版本、阶段产物和事件，未完成时也可以查询已经有效的部分。



异常、取消、预算耗尽可以提前停止；每阶段保留有效部分

运行对象跨越请求生命周期：POST 返回后后台仍执行，页面可以刷新；Model Adapter、Retriever 的资源则属于服务装配，必须在停止时排空或关闭。SQLite 记录跨越进程重启，页面内存中的令牌不跨越刷新。理解这些不同寿命，才能解释为什么页面关闭不等于任务取消。

2.3 为什么不另建前端构建系统

本机演示需要的是明确身份、可查看证据和可追加复核，不需要复杂客户端状态框架。现有 backend 同源提供 HTML/CSS/JavaScript，减少双端端口、CORS、构建链和配置漂移。代价是页面逻辑需要自己处理并发起响应、错误状态和安全文本渲染；项目通过显式请求锁及视图代次控制这些问题。

这是一项原型规模的取舍，不是宣称所有项目都不应使用前端框架。若未来出现多页面权限、复杂编辑、模块化组件复用，必须重新评估；当前任务没有引入这些范围。

阅读入口：[backend/api.py](#)、[backend/service.py](#)、[backend/assembly.py](#)、[harness/runtime.py](#)、[backend/static/app.js](#)。先从一次提交追踪调用，再回头读辅助类型，能避免在所有历史 Agent 模块之间迷失。

2.4 图中三类关系

实线箭头表示控制调用：页面→API→应用服务→Harness，以及Harness调用审核组件。蓝色虚线表示数据访问：Retriever读取固定知识库，应用服务读取/更新运行SQLite。橙色点线表示观察回调：Harness将检查点snapshot交给应用服务注册的observer，再由RunStore写事务。

Harness不直接持有运行数据库，也不自行选择路径；运行SQLite与知识SQLite不是同一个库。图中把这两类库分开，才能解释取消、重启和原文回查的不同责任。Model Adapter与Agent在图中聚合为受控组件，省略内部调用层级；不是表示所有组件直接访问两个数据库。

Mermaid图源为 [docs/handbook-diagrams-r1.md](#)。关系颜色用于阅读辅助，线型与标签同时保留，黑白打印仍可区分。

3. 四 Agent、主张提取与 Harness

3.1 “Agent” 在本项目中的含义

四 Agent 是职责分离的受控组件：Generation 生成证据约束的初稿；EvidenceVerification 判断事实与依据；PowerDomainReview 检查领域适用条件和缺失前提；Revision 根据已观察发现作有限修改。它们没有自由创建无限任务，也没有权力越过预算或批准自身结果。

ClaimExtractor 是单独服务，不应为了凑“四 Agent”把它隐藏或合并到事实审核中。它将冻结回答映射成原子主张、回答区间和审核义务，影响下游到底审核什么。提取错误会传播到两个审核分支，所以它并不是无风险的预处理。

Harness 是控制器，不是第五个自由判断模型。它决定何时调用组件、如何记录阶段、何时停止；业务结论由确定性政策根据结构化发现计算。模型可以提出理由，但不能单凭“看起来已完成”跳过必需阶段。

3.2 当前真实装配的版本表

组件	当前服务显式采用	重要边界
Generation	evidence-bound-generation-v3-answer-units	程序定位实际回答单元
ClaimExtractor	atomic-claims-v7-obligations	目标、角色及义务仍可能有语义错误
事实审核	schema12 / evidence-verification-v9.4-standalone-templates	独立模板，类型依据与版本校验
领域审核	power-domain-review-v3.1-applicability	缺工程前提时不能虚构评估
Revision	bounded-revision-v2-per-finding-actions	每个冻结 finding 均需交代动作
确定性政策	limited-repair-policy-v1	最多一次修订，仍需人工复核
演示领域规则	power-demo-rules-v1.1	不是经过生产审定的电力规程

代码中保留旧版契约用于历史解释和测试，不意味着当前 API 使用旧版。个别 finding 的复用 checker 标签也不应替代运行 manifest 和实际请求模板；确认版本必须从装配、输出 prompt_version 和冻结归档交叉核对。

3.3 冻结回答与共享主张

冻结意味着某轮审核的 answer_id、answer_version、全文及区间不再随模型临时修改。两个审核分支接受同一份提取结果，减少“一个分支在审甲回答，另一个在审乙回答”的漂移。Revision 产生新版本，不原地改写 v1；新版本必须重新提取，旧主张不能被直接复用为 v2 的审核结论。

共享主张让目标一致，却也形成共同上游风险：若提取器把技术断言错分为回答范围声明，两个分支都可能收到错误任务。双审的职责独立并不等于统计独立；当前使用同一提供方模型，还共享提取结果，不能宣称已通过多模型投票消除了相关错误。

3.4 如何读模型契约

先看输入：冻结回答、claims、quote candidates、工具结果及允许类型；再看输出：每个 finding 需要什么身份、状态与 bases；最后看校验器如何拒绝未知 ID、错版本及不属于该 claim 的依据。提示词只是告诉模型该做什么，程序校验器才决定返回数据能否进入当前运行。

一个合法 JSON 也可能是错误判断。程序能验证区间、类型和身份，通常不能直接证明模型正确理解了句子的语义。面试时应主动用第 12 章的目标分类漏检说明这个边界，而不是把 schema12 当成“已经解决幻觉”。

阅读入口：agents/contracts.py、services/claim_extractor.py、agents/review_templates_v3.py、agents/verification_contract_v9_scoped.py、services/review_fidelity.py。

4. 知识入库、原文与 PDF 质量边界

4.1 原文和检索文本为什么分开

检索需要去噪、分词或规范化，引用却需要精确回到原文。项目保存 raw text，并另外派生 search_text。只修改搜索表示，不把规范化后的空格、单位或标点写回 Evidence。否则一个看似方便的预处理可能让 quote offsets 无法回查，甚至让“引用原文”变成程序重写的文本。

Markdown 与 PDF 的来源对象、片段及派生版本都通过存储层建立关联。原文件哈希、解析器信息和切分版本属于可复现性线索；它们能说明某个片段来自哪次解析，不能说明解析内容已经被人工逐页视觉核对。

4.2 PDF 文本不是视觉原文

PDF 可能有多栏、跨页表格、上下标、公式和页眉。解析出的字符顺序不一定等于视觉阅读顺序。当前资料回查展示的是提取文本，并保留质量告警，如视觉未核对、公式或表格未解释。界面不能把它称为“已核验的 PDF 原文”。

pdf-paragraphs-v2 优先使用可靠空行段落边界，长段按有界窗口切分，最大约 1200 字符；不在 CRLF 中间切断。派生片段基于已保存的页文本生成，不为每个实验重新解析官方文件。这样可以把切分变化与解析变化分开追踪。

资料处理层	保存的对象	需要保留的疑问
文件接入	文件来源、哈希、文档身份	版权、地域、版本与获取是否成功
文本解析	页文本、解析器版本	视觉顺序、公式和表格是否可靠
片段派生	原文区间、页码、切分版本	边界是否切开必要条件
搜索表示	search_text、索引配置	去噪是否改变召回，不改变原文
Evidence 展示	文本与原文定位、质量告警	支持关系仍须模型及人工评估

4.3 当前公开资料和获取失败

资料说明登记了三份实际获取的公开来源：NERC Reactive 指南、VAR 标准资料及 PNNL 报告。PDF 质量派生记录分别为 57 页/268 片段、16 页/40 片段、54 页/116 片段，合计 127 页、424 派生片段。这是入库规模，不是 424 个正确答案或全部已视觉核验的证据。

AEMO 获取曾返回 403，没有因此虚构已入库内容，也没有自动绕过访问限制。官方全文留在本机忽略的 data 目录；公开可访问不自动等于允许项目重新分发全文。Git 中保存来源 manifest、说明及开发问题，不提交整份 PDF。

4.4 相邻上下文

检索命中片段可能需要前后条件，因此 Harness 的当前装配启用有界相邻上下文。上下文来自相同文档版本的机械邻接，保持各片段自己的 Evidence 身份，不给邻居伪造核心命中的排名或相似度。超出预算时省略整个片段，不切成无法定位的新引文。

相邻不保证语义连续，跨页也不保证同一表格。曾有 cross_page_next_first 交付实验，未被自动推广为默认配置。特别注意：某些 CLI 文档中“默认关闭上下文”的描述指该命令入口，当前真实 Harness 的 ContextOptions 装配应看 backend/assembly.py，不能仅凭历史文档推断。

阅读依据：rag/markdown.py、rag/pdf.py、rag/pdf_chunks.py、rag/storage.py、rag/context.py、docs/pdf-retrieval-quality.md、docs/knowledge-sources/manifest.json。

5. BM25、Dense、RRF 与检索取舍

5.1 当前默认为什么仍是 BM25

BM25 用词项出现、文档长度和集合频率计算相关性。当前实现对拉丁文本提取小写词项，对中文使用单字和双字组合；查询词去重，只保留分值大于零的片段，先按BM25分数降序主排序，平分才使用稳定身份。平分键依次为 document_id、version、ordinal、fragment_id，按字段本身的升序比较，不依赖SQL返回顺序或插入时间；version的升序不是“优先最新版本”，候选已受固定快照限制。参数 $k1=1.5$ 、 $b=0.75$ ，使用正值 IDF。默认服务使用 AsyncSQLiteBM25Retriever，核心结果数量为 3，再装配有界上下文。

它的优点是容易追踪、资源要求低、无需模型编码服务；局限是同义表达、跨语言和自然问题不一定命中术语。BM25 分数解释的是查询与搜索表示的词项关系，并不是文件权威性 or 回答正确概率。

5.2 Dense 编码的实际实现

可选 Dense 路径采用固定 revision 的 multilingual-e5-small，384 维、FP32 ONNX CPU，分别编码 query 与 passage。attention mask 均值池化后 L2 归一化；长文档以 480 token 窗口、448 stride 分段，各窗口先做mask均值池化；窗口池化向量等权平均后才做一次L2归一化，并非先逐窗口L2后再平均。最大批量为 4。具体 revision 与文件哈希见 rag/embedding.py，不是运行时随意下载最新版。

向量只是一种搜索派生物，不替代 raw text。索引建立时记录 encoder profile、知识版本和来源指纹；维数、有限值与快照完整性都需检查。若向量缺失，不能悄悄把不完整 Dense 排名说成同一完整实验。索引构建采用原子更新，失败回滚，不污染已有知识表示。

5.3 RRF 的意义与边界

RRF 按名次融合，不要求 BM25 与余弦分值在同一尺度。当前可选实现使用 $k=60$ 、两路等权、候选深度 50，Dense 仅使用正相关候选。直观上，片段在两种方法都靠前会得到更高融合值；但融合仍然只是检索排序，并没有执行事实审核。

例如某段全文同时讨论 active power 和 reactive power，可能因词项或语义匹配进入前列。它是否支持“active power 是某种 reactive rating”，仍要审查句子关系，不能由排名替代。第 12 章的类别误判就是这种边界。

5.4 重排序和术语扩展为何没有成为默认

可选 reranker 使用固定 mmarco-mMiniLMv2-L12-H384-v1，int8 CPU、512 token、批量 2；只截断候选侧，过长查询拒绝。输出原始 logit，不是支持概率。固定候选池实验出现局部改善，也出现必要组合退步；关键已标退步不能统一归因于截断，因此没有采用为默认。

术语扩展实验及 27 条补标后的对称回算显示 BM25 局部收益，没有改善最终完整依据指标，保留基线。正文优先、编码核查等都是独立历史实验，不应因为代码存在就称当前服务已启用。这里记录的是具体报告的取舍，不主张 BM25 永远优于 Dense。

路径	当前状态	与事实审核的关系
BM25 + 有界上下文	当前服务默认	提供候选依据，判断仍在审核层
E5 Dense / RRF	可选实现和历史实验	不自动替代默认，不表示语义正确
术语扩展	实验结束，未采用	相关性局部改善不等于完整支持
固定 reranker	实验结束，未采用	logit 不能作为可信总分

本章依据: rag/bm25.py、rag/embedding.py、rag/semantic.py、rag/reranker.py; 报告索引见 docs/documentation-index.md 的检索实验表。手册编写没有重跑这些实验，也未下载模型。

5.5 BM25公式和三个因素

令查询去重词项集合为Q，语料有N个候选片段，df(t)为含词t的片段数，tf(t,d)为该词在片段d中的次数，L(d)为分词后token数，avgL为平均token数。本项目实际公式为：

```

IDF(t) = ln(1 + (N - df(t) + 0.5) / (df(t) + 0.5))
score(d,Q) = sum over t in Q:
  IDF(t) * tf(t,d) * (k1 + 1)
  / [tf(t,d) + k1 * (1 - b + b * L(d)/avgL)]
k1 = 1.5; b = 0.75

```

TF提高意味着词项多次出现，但分式趋近k1+1，收益饱和，不是出现两次就两倍分数。IDF让稀有词通常贡献更大；这里ln-positive-idf即使词遍及全部片段仍为正。长度归一化降低长文仅因有更多词而占优的倾向；b=0不考虑长度，b越大长度作用越强。

长度是实际tokenizer产生的token数，不是原文字符数。中文单字加双字会影响长度，不能拿英文词数公式直接代替中文分词结果。查询重复词去重，不引入额外query-TF倍数；空查询或平均长度为零时返回全零。

5.6 小型BM25排序手算

以下四个英文片段是教学构造，不是知识库或新实验。查询只有voltage，N=4，df=4，avgL=3.75，IDF=ln(1+0.5/4.5)≈0.105361。

片段	token序列 / 长度	tf / score
D1, document_id=z	voltage voltage control / 3	2 / 0.160856
D2, document_id=c	voltage control current / 3	1 / 0.115781
D3, document_id=a	voltage current current current current current / 6	1 / 0.082961
D4, document_id=b	voltage control current / 3	1 / 0.115781

D1分数最高，尽管document_id=z仍排第一，说明身份不是主排序。D2和D4完全平分，假定其他键一致，b先于c，所以D4在D2之前。最终D1、D4、D2、D3。D3虽身份最小，却因长度惩罚得分最低；D2和D4相同正文仍可有独立来源身份。

代入D1的TF因子： $5/[2+1.5*(0.25+0.75*3/3.75)] = 5/3.275 \approx 1.526718$ ；乘IDF得分。保留小数仅为解释，源码排序使用未四舍五入的float。实际平分必须是分值相等，不能自行设“相差很小就平分”。

5.7 E5输入、池化与余弦

实际编码器拼接 query: +查询或 passage: +片段，例如query: voltage control与passage: reactive power supports voltage。前缀不改写Evidence原文；tokenizer检查前缀边界，空文本拒绝，query超512 token拒绝而不静默截断。passage长文本按480/448窗口处理。

模型输出hidden的形状为batch×tokens×384。attention_mask=1的token参与均值，padding=0被排除： $m = \text{sum}(\text{mask}_i * h_i) / \text{sum}(\text{mask}_i)$ 。当前实现也包含非padding的特殊token/前缀位置，不另设正文专用mask。每份文本的窗口池化向量等权平均，再 $u = m / \|m\|_2$ ；非有限值或零范数触发ContractError。

用二维教学向量代替实际384维：两个有效hidden为(2,4)、(4,4)，平均 $m = (3,4)$ ，L2范数5， $u = (0.6, 0.8)$ 。padding即使有其他值也不计入。另一文本 $v = (0.8, 0.6)$ 已归一化， $\cos(u, v) = u \cdot v = 0.48 + 0.48 = 0.96$ 。

一般 $\cos(q, d) = (q \cdot d) / (\|q\|_2 * \|d\|_2)$ ，两者都L2归一化后可直接点积。这个0.96是教学相似度，不是事实支持概率。当前默认API没有启用Dense；这段说明解释已存在的可选编码与搜索实现，没有调用模型或重建向量。

5.8 RRF公式与两路手算

$\text{RRF}(d) = \text{sum over lists } j: 1/(60 + \text{rank}_j(d))$ ，名次从1开始，未进入某路候选就没有该路贡献，不能当成rank=0。当前等权，两路候选各截到50，再融合后取需要的结果；不混合BM25原始分值和余弦尺度。

片段	BM25名次 / Dense名次	RRF分值
A	1 / 4	$1/61 + 1/64 \approx 0.032018$
B	2 / 1	$1/62 + 1/61 \approx 0.032522$
C	3 / 2	$1/63 + 1/62 \approx 0.032002$
D	4 / 3	$1/64 + 1/63 \approx 0.031498$

融合排序B、A、C、D。B在两路都靠前，得分最高；A与C很接近，但A略高。这是名次算术，不需要再次编码。平分仍按固定身份键，保证同样输入可复现。

5.9 为什么完整组合反而退步

假设回答需要B提供条件、C提供结论，必要组为{B,C}，只取top2。Dense的B、C满足完整组合；融合后B、A让C落到第三，组合覆盖由2/2降至1/2。A可以很相关，但并非C的替代证据。RRF逐片段融合，不以“满足必要组合”作为优化目标，所以局部名次收益与完整依据收益可以相反。

这个手算仅说明可能机制，不推断历史模型内因。项目历史术语扩展/重排序报告另有实际组合退步证据，应查固定候选、截断和标注分母；不要拿教学例子宣称已解释每个真实退步。

6. 版本、引用、快照与严格类型依据

6.1 不同身份回答不同问题

文档身份回答“哪份资料”；派生版本回答“哪次解析和切分”；knowledge_version 回答“哪个固定知识快照”；evidence_id 回答“哪份可回查依据对象”；quote_id 回答“这次候选中的哪段引文”；answer_id 与 answer_version 回答“哪个回答的哪一版”；claim_id 与 finding_id 回答“审核目标与判断是哪条”。这些字段不能混用。

字符区间只有放回指定版本全文才有意义。相同文字出现在两个页或两个回答版本里，身份仍可能不同。程序定位使用实际字符串与区间，不允许模型凭记忆提供似是而非的 offset。生成回答的 answer units 也由程序计算范围，避免让模型猜测全文位置。

6.2 严格类型依据

审核目标或依据类型	可以支持的判断	不能偷换成什么
text_excerpt	技术事实与具体原文关系	元数据、相似度或仅标题
metadata_reference	登记字段或来源质量描述	已人工核对官方正文
input_snapshot_reference	输入中是否提供指定信息	未交付全文的完整覆盖
answer_text_reference	回答确实写了某句或限定范围	该句在世界中为真
calculation_result_reference	已执行、成功且绑定本 claim 的有限计算	任意其他 claim 的结果或工程仿真

core/typed_evidence.py 及作用域校验把这些关系变成程序约束。引用原文必须精确匹配允许的候选，未知 ID、错范围或跨版本依据不能进入结果。请求内的 wire ID 可带命名空间，以避免不同批次对象碰撞；回查时应使用服务保存的正式身份。

6.3 原引用与独立检索必须分开

原引用审核问“回答引用的这段来源是否真的支持对应单元”；独立检索问“当前知识快照有没有其他支持”。独立找到正确资料，不能回头证明原回答那条引用也正确。用户参考、登记元数据、网页标题与官方正文同样不是等价对象。

在真实问答历史中，事实主张可以得到独立支持，同时原引用覆盖仍有警告。这是两种审核义务，而不是服务自相矛盾。界面分别展示角色，不把一个 evidence_id 列表全部归为“原引用已验证”。

6.4 提取忠实性与事实真值

faithful 表示提取目标忠实于回答；supported 表示对目标给定依据的支持关系。回答原本说“四类”，提取器必须保留这个断言，然后由事实审核判断其真假。若把错误目标改成别的命题，模型可能正确审核了错误对象。

程序能要求 fidelity 类型、义务和依据一致；disputed 或 mismatch 时不能假装完成事实支持。但模型自报 faithful 仍可能语义错误。第 12 章 N12 案例说明：上游把技术断言错分为 answer_scope，后续合法 supported 只证明回答写了这句话，并没有证明技术内容。

6.5 快照兼容与历史保存

历史结果应按它当时的知识、协议和提示解释。新 checker 出现后，不重新写旧记录使它看似通过。归档中应保存配置/版本哈希、原始响应索引及失败矩阵；公开说明仅引用必要内容，不复制私有响应。当前默认知识版本在 backend/config.py，完整值以冻结计划为准。

代码入口：core/models.py、core/typed_evidence.py、services/text_location.py、services/answer_units.py、services/scoped_candidates.py、services/evidence_scope.py、services/answer_anchors.py。阅读时选择一条 finding，逆向查到 claim、回答版本、typed basis 和原文，是最有效的练习。

7. 工具、预算、超时和取消

7.1 有限工具能够确定什么

SI 标量换算工具能确定已知单位比例，例如 $230\text{ kV} = 230000\text{ V}$ 。它不判断系统额定电压是否可接受，不补造标么基准，也不执行工程仿真。工具结果必须成功、注册在本运行并绑定具体 frozen claim；模型不能拿另一个主张的计算结果作为自己的依据。

程序还有数量/枚举与结构化输入单位检查。当前 schema12 相关数量路径会将指定 v1.2 检查提升为 v1.3 的封闭正向声明语法；不因否定、转述或模型角色标签就认定数量断言成立。语法识别不了的文本报告 incomplete，而不是强行给出全局正确或错误结论。

7.2 程序规则与模型判断并列保存

假如模型把“类别数量为四”判为 supported，而程序在限定语法中观察到仅三个 rating 项并产生 warning，两个结果都保留。warning 不被包装成模型正确识别。相反，规则显示一致也不能证明模型理解了类别成员关系；规则只覆盖其显式语法。

自由文本没有结构化 quantities 时，输入单位检查会说明未完成完整单位审核。项目不能从一句概念回答虚构电网数据填入工具，也不能为了得到 completed 而把缺失输入默认成零。

7.3 服务端预算是权威

预算项	当前默认值	工程意义
模型请求	40	格式纠正和失败尝试也占用
Revision	最多 1 次	防止无限自我修订
总时长	800 秒	整个运行的截止时间
单步时长	110 秒	不超过剩余总预算
瞬态自动重试	0	不暗中重复付费请求
累计检索字符	160000	控制上下文交付量

更细的工具/检索上限见 [harness/contracts.py](#)；模型适配器自身还有请求超时、输出 token 和响应字符约束。浏览器不拥有调整这些上限的权力。真实验证时若采用独立预算，必须冻结记录并区分默认配置，不能把临时验收设置说成日常默认。

共享 ModelBudget 在实际尝试前扣计数，通过运行上下文作用于双审及格式纠正。若两个分支并发，记录完成顺序不一定等于 call number；统计应使用真实请求编号和 usage，不能仅按列表位置假设。

7.4 取消为何不是立即停止一切

取消是合作式信号。Harness 在阶段和受控调用边界检查状态，远端已经接收的模型请求未必能撤回。异步超时也不能物理杀死所有底层线程。AsyncSQLite Retriever 使用受控工作线程，取消包装等待不表示线程工作已结束，资源排空后才能关闭或复用。

因此页面先显示“已请求取消”，等待服务确认实际终态；不能仅凭按钮点击就显示 cancelled。已经有效保存的部分结果仍可回查。超时、网络失败、取消和 interrupted 分别记录，不合并成“资料不足”。

本章依据：[tools/unit_conversion.py](#)、[tools/scalar_numbers.py](#)、[services/quantity_checks.py](#)、[harness/contracts.py](#)、[model_adapter/runtime.py](#)、[harness/retrieval.py](#)、[rag/retriever.py](#)。工程上重要的是受控资源和失败可解释，不是承诺瞬时取消。

8. 有限修订与完整重审

8.1 为什么不能把 Revision 当成纠错保证

Revision 模型收到初审发现后，可以尝试最小修改，但也可能保留错误、引入新主张或省略限定条件。因此修订后的文本不是自动通过的结果。当前政策最多允许一次修订，新版本必须重新提取并完成事实与领域双审。

LimitedRepairPolicy 只对已观察的矛盾、证据不足、领域 warning 或程序 warning 提供有限修订机会。必要审核有执行问题时，不绕过它们去制造闭环完成。缺失工程检查仍保留，修订不能凭空获得厂站参数或仿真结论。

harness/policy.py 的方法内实际摘录如下；base 是此前基础政策计算的决策。这条提前返回让执行问题保持优先，不因后面存在可修复发现就继续修订。

```
if verification.execution_issues or domain_review.execution_issues:
    return base
```

8.2 每个 finding 都有动作记录

bounded-revision-v2-per-finding-actions 要求冻结的事实与领域发现逐项交代 modified、retained 或 unresolved，并保留身份关联。至少存在真实 modified 且回答发生变化，才能构成有效修订。某条写成 modified 也不等于它已解决，最终解决状态只能从重审判断。

动作	表示什么	重审还要检查什么
modified	回答对该问题做了实际修改	是否改对、有无新主张
retained	保留某项内容或限定	保留是否合理、是否仍未解决
unresolved	无法用当前输入解决	是否需要人工补证据或前提

动作记录是一种账目完整性，不是正确性证明。它让用户看见“改了哪条、没有改哪条”，避免模型只写一句“所有问题已修复”而无法核查。retained 的问题也可能在 unresolved 输出中继续出现，不应因措辞温和而消失。

8.3 一次修订后必须终止

重审可能发现新问题，当前基线不允许继续第二次 Revision。终止时保存未解决 finding 和原因，交给人工。只有这样，模型请求预算和用户预期才能被界定；不断修到 pass 会隐藏失败并使真实验证不可比较。

真实样例中，230 kV 换算被改正，新增“并非230 V”却仍被事实模型判为证据不足。由1 kV=1000 V可知230 kV=230000 V，当然不等于230 V；这里没有数学争议。问题是该轮模型对否定比较要求确切绑定依据、未接受现有表达，属于审核行为及目标/依据绑定限制。该模型标签保留用于研究，不能改写成数学上无法确定。用户可以针对 v2 的具体 finding 追加意见，模型判断仍留在原记录中。

8.4 分阶段读取闭环

阅读 `harness/runtime.py` 时，先识别各轮 `answer version` 和 `revision_round`，再看提取、双审、`policy`、`revision` 的连接。不要把同一个 run 的 v1 与 v2 findings 混成一张没有版本的表。也不要把历史“事实阶段独立测试”称为全闭环测试，它可能根本没有执行 `Generation`、`Revision` 或 `DomainReview`。

观察一个运行可按四个问题展开：初审是否形成有效发现？政策依据什么选择 `revise`？修订动作是否覆盖冻结问题？新版本是否完整重申且保留未解决项？第 11 章用同一个真实 run 逐项回答；历史闭环失败在第 12 章保留。

代码入口：`harness/policy.py`、`harness/runtime.py`、`agents/revision.py`、`agents/revision_contract_v2.py`。不要把提示词中的“请修复”当作流程保证，应检查程序是否要求重申和终止。

9. 本机 API、队列、事务与重启

9.1 API 是受控视图

浏览器获得的是服务投影的运行状态、结果、`trace`、`Evidence` 和反馈，不是任意读取本机文件的入口。输入模型禁止额外字段，服务端保持预算、索引路径、数据库路径和政策权威。提交 `mode` 为 `question_answer` 或 `assess_existing`，已有回答模式必须提供实际文本。

接口类别	操作	主要约束
<code>health / capabilities</code>	查看服务模式与可用能力	不泄漏密钥或私有配置
<code>POST runs</code>	新建任务	鉴权、字段与长度校验、队列容量
<code>GET state / result / trace</code>	查询已知 run	即使未结束也显示有效部分
<code>GET evidence</code>	原文与依据回查	必须属于当前运行作用域
<code>POST cancel</code>	请求取消	以实际状态确认终态
<code>GET / POST reviews</code>	查看或追加人工意见	实际回答版本和 <code>finding</code> 关系
<code>runs/page/{offset}</code>	固定大小运行列表	分页，不要求客户端读数据库

此表按职责归类，精确路由签名以 `backend/api.py` 为准。反馈或证据不能仅验证某个 ID 存在就放行，还要检查它属于请求的 run、`answer version` 和 `finding`。

9.2 事务保存什么

运行存储 SQLite 使用外键和 WAL，检查点在事务中同时写事件、对象与最新状态。事件保留过程记录，快照便于当前查询；回答、`Evidence`、`Claim` 与工具身份有不可变约束，`finding` 的进度视图可更新但历史事件继续存在。

若 `observer` 写库失败，`Harness` 不应继续付费工作而假装能够归档；服务进入存储故障处理并停止接受相关工作。一个模型结果已返回不意味着持久化一定成功，必须检查写库边界。这也是为什么程序需要执行问题，而不能把一切归入模型业务结论。

9.3 重启不重发

启动恢复把未完成 `queued/running` 任务标记 `interrupted`，保存已有有效部分，不自动重发付费请求。已完成结果与人工反馈继续保留。服务使用 `ProcessLease` 限制同一运行库多进程打开，当前 `uvicorn` 单 `worker`，避免两个服务各自声称拥有同一个活动任务。

任务状态与阶段状态是不同对象。`finished` 表示运行终止过程正常结束，`failed` 表示执行失败，`interrupted` 表示进程恢复发现未完成；业务可能仍是 `review_required`。不要把 `interrupted` 翻译成“审核判定不可信”，它说明的是执行中断。

9.4 反馈是追加记录

确认、反对、待查和说明绑定实际版本与可选 `finding`。错误版本返回 409，不覆盖原模型判断。当前本机令牌不是多用户身份系统，意见来源必须保留为本机用户/AI 辅助用户监督；不能自动称专家复核，也不能直接转为训练金标准。

如果 POST 反馈超时，页面保留文本并说明未确认保存；用户先查询已有意见，避免因重试重复追加。只显示“网络请求已发送”不能被解释成“已保存成功”。

阅读入口：`backend/api.py`、`backend/service.py`、`backend/store.py`、`backend/local_access.py`。真实重启核验在 `data/runtime_local/v0.1-acceptance/real-restart-verification.json`，与离线恢复测试分别使用。

10. Web 界面、来源链接与中文解释

10.1 安全展示是不可信文本处理

回答、证据、模型原因和人工意见均可能含 HTML 或脚本样式文本。当前页面使用 `textContent` 和 `createElement`，不直接 `innerHTML`，也未引入 Markdown 执行或不受控 HTML 渲染。CSP 将脚本、样式和连接限制在同源；不开放宽泛 CORS。

访问令牌由用户输入，仅放页面闭包内存，连接后清空输入框，刷新重新输入。它不在 URL、localStorage、源码、截图或日志中。DeepSeek 密钥只由服务端既有入口加载，浏览器不知道它。两个凭据解决的问题不同：前者访问本机服务，后者访问模型提供方。

10.2 来源 URI 的结构化投影

早期投影把宽泛“像路径的字符串”规则作用到来源 URI，合法官方 HTTPS 也被误隐藏。修复后对结构化来源字段使用 URI 解析规则：只接受公开 HTTPS，拒绝不适当协议、用户信息、私有或本机主机及不安全查询信息；未知来源保持空，不猜测。

模型字段中的敏感凭据和私有路径继续去除，但不能把 JSON 诊断位置 `$.findings[2].bases[0]` 当成本机文件路径。本轮真实批次完成并冻结后，单独修复 `field_path` 的投影误隐藏；没有在付费批次中途改代码并继续视作同一批。

外部链接只让浏览器打开来源，不由服务器自动抓取，也不附带本机 Authorization。页面设置 `noreferrer`、`noopener` 与 `no-referrer`。生成一个链接不等于已验证外站当前可达，也不等于它的全文支持当前主张。

10.3 中文摘要的四条轴

主区域分别显示运行终态、必需阶段完整性、必需检查是否全评估、业务决策与原因。摘要由实际结构化结果确定，不统一写成“资料不足”。执行错误、矛盾、证据不足、工程前提缺失和无法评估分别解释；原始英文原因及 JSON 保留在详情。

若下一步只知道某条 basis 不够，应提示查看该条 Evidence 或待人工检查；不能自动生成未经审核的电力操作建议。若结构化发现明确列出缺失前提，可说明需要补充该前提以供评估，仍不推导具体工况值。

10.4 防重复付费提交

按钮锁定防止重复点击。提交响应丢失时，任务可能已经存在，因此页面显示状态未知并先查询运行列表；不能因为 POST 超时自动重新提交。GET 网络断开也不证明任务不存在。页面恢复可使用 `run_id`，结束后停止轮询。

异步视图更新还需要代次标记：用户切换 run 后，旧请求返回不能覆盖新任务页面。服务模式变化时先停止并确认当前能力，不把 `synthetic_fixture` 结果显示成 `real`。取消仅表示已请求，最终状态等待服务确认。

本轮实际内置浏览器检查了中文摘要、合法来源链接、修订版本、Evidence、工具与反馈；截图归档不含令牌。危险文本、重复提交和错误响应还有离线/客户端回归，但这些测试不证明模型语义正确。

阅读入口：backend/serialization.py、backend/presentation.py、backend/static/app.js、tests/test_v01_presentation.py、docs/local-review-ui-v1.md。

11. 一次真实服务修订：逐阶段阅读

11.1 冻结输入与验证目标

唯一真实验收 run 为 e1c6bc1336cd4c89acee8bd2795a0ebb。它是构造的标量换算开发样例，明确不是厂站数据。通过浏览器调用本轮 API，现有真实装配和 Harness 自主执行，不在 evaluation CLI 中拼接结果，也不强制修改政策触发 Revision。

问题：请检查这个电压单位换算是否正确，并在必要时给出最小修订。

冻结已有回答：230 kV equals 230 V.

预期检查点是初审能否识别千倍换算错误、原政策是否决定一次修订、新版是否重新提取和双审、Evidence/工具/反馈是否绑定实际版本，以及重启后是否保留且不重发。预期不要求 final pass，也不把正确换算外推为工程安全。

11.2 预算预检为何先停止

最初授权最多 30 次，预检推导最坏结构为 $14+C2$ ，其中 C2 是 Revision 后原引用单元数。协议没有小于剩余预算的硬界限，因此在提交前停止，并保存预检。用户之后明确撤销上限，另建冻结计划，不能把早期停止记录删掉。

新计划按单响应最多96000字符、每个非空引用单元至少一个字符，保守取 $14+C2 \leq 96014$ ，只调整该历史验收的模型调用预算。**96014是临时异常配置，不是推荐运行方案。** 默认服务一直保留40次，其他时间、检索、纠正次数、模型与政策未改；实际只有8次。

截至本次源码核对，根本设计缺口尚未修复：Revision answer_units及原引用绑定没有与审核成本相匹配的小型显式数量上限，仍不能用40证明任意合法修订都能完成最坏引用审核。全局40请求上限仍保护费用，耗尽就停止并保存部分结果；它保证有限调用，不保证所有必需阶段完成。移除临时大预算或恢复默认不等于修复了这个协议缺口。

设计教训是“受控成本上限”和“最坏情况下阶段完整性”需要分别证明。未来可独立设计引用单元上限及成本预检，再验证其与审核义务一致；本轮没有实施这些修复，也不为赶预算跳过检查。

11.3 初审和一次 Revision

初审事实 finding 判定 contradicted，领域回答单位项给 warning；SI 工具计算 $230 \text{ kV} = 230000 \text{ V}$ ，结果绑定该冻结主张。LimitedRepairPolicy 因观察到可修复问题决定 revise，没有跳过缺失工程检查。

Revision v2 的实际文本为：“最小修订：230 kV 等于 230000 V ($1 \text{ kV} = 1000 \text{ V}$)，并非 230 V。该修订仅针对所给标量电压单位等式；未运行任何仿真或工程计算，不构成完整单位审核或工程安全结论。”

逐 finding 动作覆盖初审一条事实和六条领域发现。换算/回答单位被修改；缺工程输入、完整单位审核、仿真等问题仍 unresolved，范围限制和操作前提边界保留。动作账目不自动将这些未完成项目变成 completed。

11.4 重提取与双审的有效结果

v2 主张或限定	事实结果	应怎样理解
230 kV 等于 230000 V	supported	有对应标量工具依据
1 kV 等于 1000 V	supported	有对应比例依据
并非 230 V	insufficient_evidence	数学上成立；模型未接受对应否定比较的绑定依据，检查审核行为
仅讨论所给标量等式	supported	回答范围锚点，不是外部事实证明
未提供/未运行仿真	supported	输入快照及范围，不证明工程已分析
不构成安全结论	supported	回答限定，不是工程安全判断

共六条，五条 supported、一条 insufficient_evidence。必需阶段完成，但领域必需检查没有全部评估；最终 review_required，执行问题最终列表为空。这些状态不矛盾，不应写成“全部可信”。

11.5 真实结构失败与唯一纠正

首次事实重审把另一个 frozen claim 的计算结果绑定给当前 finding，程序拒绝，诊断为 calculation belongs to another frozen claim，位置 \$.findings[2].bases[0]。五条有效 peer 保留，错误条不凭空补齐。阶段级唯一格式纠正后，响应形成合法对象。

原失败响应、纠正响应和检查信息都保留。最终阶段成功不表示从未失败；结构纠正成功也不能解释为模型已正确审核该否定比较；数学等式本身并无争议。该剩余问题作为人工待查反馈绑定 v2 实际 finding，原模型判断不覆盖。

11.6 用量、证据与重启

8 次请求：提取 2、领域审核 2、事实审核 3（含一次格式纠正）、Revision 1。原引用调用为 0，是实际没有原引用绑定，不是删减审核。7 条 Evidence 与 7 个工具结果保存，Evidence API 回查文本一致。

输入 130256 token、输出 4168、合计 134424；缓存命中 40064、未命中 90192。耗时 38.787 秒。按当时核对的官方价目估算 0.016149792 至 0.032299584 美元，非账单；价格有时效性，不应拿本例范围作为未来承诺。

真实服务按冻结配置重启后，结果与反馈逐字段一致，请求数仍为 8，没有再次 POST 或自动重发。后来恢复默认演示服务，历史记录继续保留真实 profile。此前两个真实 API 场景共 9 次，没有 Revision，统计与本例分开。

证据路径：data/runtime_local/v0.1-acceptance/revision-review.md、verification.json、frozen-plan-authorized.json、raw-archive-verification.json、real-restart-verification.json；官方价目核对来源登记在验收归档。本手册没有产生新增付费请求。

12. 历史失败：契约修复与语义边界

12.1 模板冲突不是模型一个人的错

历史独立事实审核曾继承联合输出模板，系统示例要求 findings+citationreviews，而请求希望独立阶段根结构。模型返回混合根结构，程序拒绝。此时只说“模型不听话”会掩盖提示设计冲突；根因包括模板复用不当。

schema12 配套 standalone templates 分开了独立任务，只共享公共约束，配合更严格目标与依据校验。验证仍需检查实际响应和纠正，而不是仅证明提示里删了一个字段。历史 v2 曾有初审、Revision、重提取及领域阶段成功，但事实重审 0/2 完成，不能写成完整闭环 2/2 成功。

12.2 数量与类别的语义漏检

“四种 rating”案例中，模型把包含 active power 的列表作为支持，即使类别数量和成员关系有问题。程序在有限语法中可以对显式数量与完整列表比较，产生警告；但这不是模型正确识别了错误，也不能证明所有自然语言枚举都可机械解析。

现有数量规则逐步收紧：拒绝含混列表、否定或转述上下文，不自动把 power output 计为 rating 类别。输入格式超出识别范围时 incomplete。规则精确度改善不能被扩写为模型语义能力改善。

12.3 N10、N11、N12 的不同失败

开发组件例	实际观察	正确报告方式
N10	将提取忠实性与类别真值混淆，合法 not_assessable	没有完成预期数量错误识别
N11	纠正后仍返回非法 dimension，执行不完整	执行失败，不是合法业务不确定
N12	技术主张上游分为 answer_scope，纠正后 supported	合法结构仍可能审核错误目标

该阶段是冻结主张的事实组件测试，不是 12 个完整服务闭环；10 个 synthetic fixture 与 2 个真实资料开发例，不是独立专家验收集。历史报告中 12 个数量组件只有 11 个完成执行，N11 保留失败；不能删掉失败只计算成功响应。

12.4 单位格式修复的边界

单位工具曾对 ASCII 逗号分组作局部规范化，使 230,000.0 可解析，同时拒绝错误分组和虚假后缀。规范化仅在解析器内部，不写回原文 Evidence。修复能够证明受支持语法的计算稳定，不证明类别判断或工程适用正确。

类似地，标量 230 kV 换算成功，并不完成自由文本所有单位检查；缺少 quantities 时应报告不完整。一个过度积极的界面可能把工具成功显示成“工程校核通过”，所以 v0.1 专门分开模型、程序规则、工具与执行完整性。

12.5 失败分析的写法

一个可复查的失败条目需要：冻结输入、当时版本、原始响应索引、失败字段、有效部分、原因假设、程序修复、回归结果和剩余语义问题。原因假设应区别已证实与待查；不能仅凭一次模型输出断言模型内部推理机制。

例如本轮 field_path 被误隐藏是服务投影缺陷，有代码与回归定位；“并非 230 V” 未被支持是模型/依据绑定行为，当前任务没有做模型语义专项修复。把两者混成同一种 bug 会导致无谓重跑，甚至中途改协议后把不同批次拼接为成功。

依据：docs/review-reliability-v2.md、docs/fact-rereview-v3.md；私有逐条报告见 data/retrieval_local/deepseek/reliability-v2/、fact-rereview-v3/。这些历史失败没有被新手册或 v0.1 成功样例覆盖。

13. 测试、检索指标与监督标注

13.1 测试对象和结论分开

当前最终离线验证为 428 项通过，日志记录耗时 45.986 秒。这是当时最终源码的离线程序验证，不是 428 个独立真实模型案例。手册与上传阶段没有重跑历史实验，也没有新增模型请求；文档变动不把测试证据改称新执行。

假组件可以确定性覆盖队列、状态、取消、部分结果、版本、反馈 409、401、恶意文本、来源安全和恢复行为。真实模型验证则覆盖提供方协议与实际语义行为，但样本有限。两类应并列报告，不能用多写几百个假断言替代真实语义评测。

13.2 指标究竟数什么

指标	本项目定义要点	常见误读
Hit@5	前五是否有 grade≥2	至少一段相关不等于完整答案依据
MRR@5	首个 grade≥2 的名次倒数	后续必要片段完全缺失仍可能很高
judged-pool Recall	命中已标核心正例 / 已标候选池核心正例	不是全语料 Recall
nDCG	$gain=2^{grade-1}$ ，按名次折扣	grade1 背景贡献不等于直接支持
必要组合覆盖	某个替代组是否所有成员齐全	命中最多成员不等于完成一组
范围内完整依据	有适用标注与完整必要组	不是回答正确率或安全认证

无正例时某些指标没有定义，不能擅自把 undefined 混入平均当零；报告需写 valid n。Hit/MRR 的处理与 Recall/nDCG 的有效分母也不是完全相同，精确行为以 evaluation/supervised_retrieval.py 为准。

13.3 unknown 保留排名

未标片段保留真实名次，标为 unknown，不能当不相关删除后重排。否则一个未知的第一名被移走，已标正例从第五名变第一名，指标会虚高。相邻未标上下文同样保留未知，补充跨问题标注不插入本次检索排序制造命中。

必要证据可能有多个替代组合。应分别报告最大成员覆盖比例和是否至少完整覆盖一个组合。只召回三项中的两项可能对解释有帮助，却不能称已满足完整依据。问题还需具备 `answerable_with_scope_limits` 等资格，不能对标注为 `partial_not_sufficient` 的问题乱算完整支持。

13.4 标注来源和泄漏

当前标注是 AI 辅助、用户监督，不是独立专家金标准。曾看到已有候选或答案建议的冻结家族，不应包装成严格盲测。开发/冻结家族分开有助于减少同族泄漏，但不自动抹去此前暴露。

语言、自然问题/关键词、问题家族需分别汇总；同一概念换几种问法的样本相关，不能简单当许多独立问题。家族宏平均用于减轻某族数量较多的影响。反馈来源也需保留，确认意见不是自动高质量训练标签。

13.5 一个指标改善后应追问什么

先看分母与 `unknown` 是否变了，再看是否只在开发问题改善，最后看完整必要组合有没有退步。术语扩展的局部 Hit 改善未形成完整依据收益，`reranker` 局部提升伴随组合退步，这正是未采用的理由。没有必要为了漂亮分数重跑直到找到有利配置。

依据：`evaluation/supervised_retrieval.py`、`evaluation/term_supervised_final.py`、`evaluation/reranker_report.py` 及文档索引中的监督评测报告。源码、标注和实验是不同证据，面试时应说明它们怎样共同限制结论。

13.6 unknown下的Hit/MRR界限

前五名为[A未知，B背景grade1，C已知相关grade2，D未知，E已知不相关grade0]。不删除A/D，不压缩名次。数学上已有C在前三，真实Hit@5必为1；MRR最低1/3，若A补标为相关则最高1，所以 $MRR \in [1/3, 1]$ 。这是在保留排序条件下对未知标签的界限分析，不是将unknown记为0。

另一例前五名[A已知0，B未知，C已知1，D未知，E已知0]，没有已知正例：Hit@5 $\in [0, 1]$ ，MRR $\in [0, 1/2]$ 。最乐观首次正例是第2名，不能把B搬到第1名算上界1；若所有未知最终不相关，MRR为0。

实际评测器更保守：`score_question.hit_rr`只要top5有unknown，就返回(None,None)，即使上例C已知相关也不输出确定Hit=1。聚合只统计非None，并报告有效n。本节界限是教学分析，没有新增评测字段、修改程序或重算历史指标；不能把界限替换成已报告的实测均值。

13.7 必要组合和unknown同时存在

保留第一例排序，已标必要组G1={C,F}，另一替代组G2={C,G,H}，F/G/H均不在top5。G1覆盖1/2，G2覆盖1/3；最大成员覆盖=1/2，`any_complete=False`。即使已知Hit为1，也不形成完整组。

若某个已登记组成员都在top5但其中有unknown，程序按ID计算组覆盖仍可能True，并另外列`unknown_label_ids`；这只表示组成员被检索到，不证明标签和支持关系已核实。范围内完整依据还受`answerability`、`partial_not_sufficient`等标注资格限制，更不等于生成答案正确。

分母是当前已标候选池；缺失知识库之外的资料或未标正例没有被凭空补进Recall。阅读报告时同时看unknown、有效n、必要组、标注资格，不能只挑一个Hit数字。

13.8 教学算例与实验的边界

本手册BM25、余弦、RRF和unknown例子都为小型构造手算，仅验证公式理解。复核这些算术不调用Retriever真实索引、不编码E5、不发模型请求，也不是新的检索实验。真正历史效果继续依据原冻结报告，不因本轮讲解而更新任何指标。

14. 本机运行、排错与交付恢复

14.1 环境与两种模式

项目解释器固定为 D:\PowerTrustAI\venv\Scripts\python.exe。已有环境不重建；API 依赖使用 requirements-api.lock.txt。演示模式不加载 .env、不读取真实知识索引、不调用付费 API，页面明确 synthetic_fixture。真实模式通过既有加载器读取项目根配置，环境变量优先。日常使用由用户在真实模式下主动提交，沿用默认预算和政策，不要求每次编写实验授权或冻结计划；真实调用会产生费用。只有对照、验收等要形成可比较结论的实验批次，才另外记录冻结输入、配置、上限与失败停止条件。

```
cd D:\PowerTrustAI
& .\venv\Scripts\python.exe -m backend --demo --port 8765
# 日常真实使用去掉 --demo；会产生模型费用
```

页面为 <http://127.0.0.1:8765/>，只监听本机回环。终端 Ctrl+C 停止。确认端口占用者后再更换端口，不启动两个操作同一库的服务。启动/健康查询没有模型调用，但真实提交会付费。

14.2 用户在本机查看令牌

首次启动生成令牌并保存于忽略目录，重启复用。用户可在本机记事本查看后填入页面，不加 Bearer。切勿发到聊天、日志或截图。

```
notepad.exe D:\PowerTrustAI\data\runtime_local\access-token
```

DeepSeek 密钥与令牌分开：前者仅服务端读取，后者是浏览器访问本机 API 的凭据。本手册只介绍配置入口和区别，不展示任一实际值；也不建议把令牌写到 URL 方便分享。

14.3 按错误性质排查

表现	首先检查	不应自动做什么
401	页面重新输入本机令牌	输出令牌或模型密钥
409	实际 run、回答版本与 finding	覆盖原反馈或猜新版本
429	活动任务与等待队列	反复 POST 抢队列
422	必填字段、模式、长度	编造工程参数
503	服务、索引与配置状态	自动退回假组件装作真实结果
网络断开	run_id 与历史列表	把失败解释成任务不存在
interrupted	重启恢复及有效部分	自动重发付费批次

运行未结束也可查询 result；缺信息显示未提供。若反馈超时保留输入并先回查。日常运行中模型或服务不可用就保存执行问题，不自动重发；冻结实验另按其预定停止条件执行。

14.4 验证和恢复基线

```
& .\venv\Scripts\python.exe -m unittest discover -s tests -v
git -c safe.directory=D:/PowerTrustAI status --short
git -c safe.directory=D:/PowerTrustAI log --oneline -5
```

Git 基线 3d5e0cd842a1039731aafb209fb5444bd1905622 包含明确审核的 218 个源码、测试、依赖和非敏感文档，全部历史 blob 核对完成。数据、凭据、模型、官方全文及旧独立仓库排除。Git 能恢复代码，不能替代本机私有数据备份；不要把数据库或原始响应加进 Git 来补这个缺口。

2026-10-04前轮只读网络检查记录连接重置及未推送；本轮没有重新检查可达性或远端refs。以后接续上传时需先查询当时远端并比较历史，不使用这条历史记录推断当前远端为空。记录与本机排查步骤见 [docs/github-upload-troubleshooting.md](#)。

14.5 可复现记录的最小集合

保留冻结输入、知识版本、配置/代码哈希、调用上限、停止条件、实际请求/响应索引、usage、耗时、纠正记录、最终与部分结果。私有记录留 data；公开文档给必要摘要。源码快照与 Git 提交都应指明状态，不能把尚未提交文件称为可回退提交。

统一使用入口是 [docs/prototype-v0.1.md](#)；本章帮助解释运行机制，仍应从该入口确认当前启动方式。未来源码改变后，旧测试与本手册不能自动代表新版本。

15. 技术取舍、旧项目迁移和后续微调

15.1 保留、改写、替换、弃用

项目要素	处理	原因与状态
Python 工程结构与通用工具思想	经审查保留	可复用不等于沿用旧语义规则
用户提交与展示	改写为当前同源 Web/API	绑定版本、作用域和明确状态
旧评分式可信判断	用 typed findings + 确定性政策替换	权重分数没有验证成安全依据
旧六维阈值/默认参考/关键词规则	不作为生产依据	保留历史，不包装成当前规范
Dense、术语扩展、reranker	保留可选实验，未启用默认	缺少稳定完整依据收益
任意模型无限修订	不采用	成本与失败不可界定
多用户、公网、微调	未实现	不混入当前原型交付

power-system-hallucination-risk-assessor/ 是独立旧仓库，当前不修改、不展开 Git 跟踪。旧项目的文档可以说明历史动机，但旧结论不自动升级为现有审核依据。手册编写和上传审计都没有遍历其内容。

15.2 为什么优先可回查而不是“智能总分”

综合分数容易掩盖哪条主张、哪种依据和哪项未完成检查。当前项目选择对象身份、版本、原文区间、typed bases 和追加反馈，让用户能看见结论的来源及失败。代价是显示更复杂，用户需要理解 supported、not_assessable 与执行问题的区别，因此 v0.1 增加中文摘要而没有简化成绿灯批准。

这不是断言分数永远无用。若未来有明确任务、专家标注和校准评测，可以独立研究概率或排序；在现有证据下，不应把相关性分值或规则票数称为可信度。

15.3 后续微调尚未实施

当前没有事实支持判断的训练管线。本轮留下 N10/N11/N12、否定比较、类别数量等失败素材，为未来研究提供候选，不等于已经获得可训练金标准。第一步应是专业核实目标和答案、来源权限与必要证据，而不是把所有用户确认反馈直接导入模型。

建议将样本拆成技术事实支持、提取忠实性、目标分类、依据类型、工程适用条件等任务，防止一个标签同时表达多种失败。记录输入、资料版本、模型版本、人工来源和争议；含私有厂站资料的案例先处理权限，不自动公开。

15.4 采用与停止条件

按问题族划分训练/开发/独立测试，避免同一事实换措辞泄漏。冻结测试不只看合法 JSON，还看 contradicted/insufficient/not_assessable 的语义、错误目标、缺前提及过度支持；保留有效分母和未知项。必须与未训练基线同条件比较，不只报告挑选后的改善例。

成本包括标注、训练、推理与维护。采用条件应在实验前定义：关键错误降低、未引入重要退步、权限满足、成本可接受；停止条件包括无法取得可靠标签、收益不稳定、工程建议误支持增加或预算超出。具体阈值尚未设计，也没有本轮授权执行新实验。

15.5 本机原型是否可冻结

具备冻结本机人工辅助原型的条件：统一服务、界面、持久化和一次真实修订已验证，剩余语义问题如实保留。不能宣称生产验收或安全认证。来源视觉未核对、工程前提缺失、模型目标误分类及样本覆盖有限，不断阻用户监督下的本机阅读与复核，但阻断自动采信和工程批准。

依据：docs/legacy-migration-principles.md、docs/design-decisions.md、docs/fact-rereview-v3.md、docs/prototype-v0.1.md。后续方案是建议与待授权工作，本手册交付不启动下一轮。

16. 面试问题、追问和回答证据

16.1 入门：用完整流程回答

问题：PowerTrustAI 与普通 RAG 问答有什么不同？

回答思路：先说明两个入口复用 Harness；回答冻结后提取主张，事实与领域双审，typed bases 回查，确定性政策决定最多一次修订，保存版本与人工反馈。不要只说“用了四个 Agent”。普通检索生成是其中一段，项目还处理运行完整性、失败与恢复。

追问：证据检索命中就表示回答正确吗？答：不表示；BM25/Dense 只产生候选，原引用和独立证据分别审核，模型仍可能把相关内容误当支持。证据入口：`backend/assembly.py`、`harness/runtime.py`、第 12 章类别例。

问题：为什么叫 OfflineHarness，还能调用真实模型？

回答思路：名称沿用离线工程抽象，真实组件通过注入装配，演示与真实复用调度而非复用结果。强调 `synthetic_fixture` 标识和真实配置失败不偷偷回退假组件。追问可展示 `factory` 与 `ServiceConfig`，不拿假响应证明真实模型能力。

问题：ClaimExtractor 是第五个 Agent 吗？

回答思路：本项目将四个有名称的 Agent 与提取服务分开；职责比数量重要。提取器建立目标与义务，Harness 控制流程，不参与自由模型投票。追问：提取错了怎么办？说明 `fidelity` 程序检查与 N12 剩余语义风险。

16.2 中级：解释身份和数据边界

问题：为什么需要 answer version，直接覆盖答案不更简单吗？

回答思路：`finding`、`Evidence`、工具和反馈都要指向实际文本；修订改写后旧 `offset` 不能复用。保存 `v1/v2` 能复查改了什么，并防止反馈绑定不存在的版本。证据：`core/models.py`、`backend/store.py`、`agents/revision_contract_v2.py`。

追问：修改过的 `finding` 是否代表解决？答：动作只是账目，重审才产生新判断；真实 `v2` 仍有“并非 230 V”证据不足。不要说修改后自动 `pass`。

问题：如何避免另一个运行的 evidence_id 被查询？

回答思路：鉴权只是第一层，`Evidence`/反馈还要检查 `run` 作用域及回答/`finding` 关系。模型依据也要求 `frozen claim` 和版本相符。真实重审曾错用另一个 `claim` 的计算结果，程序拒绝，说明身份校验能够实际阻断一种错误。

问题：为什么不直接 innerHTML 展示模型 Markdown？

回答思路：模型与用户文本不可信，首版纯文本满足功能，`textContent` 配合 CSP；若未来支持 Markdown 必须独立安全处理，不能以模型“不会生成脚本”为保证。来源 URI 也按结构化协议、主机与敏感信息验证。

16.3 进阶：成本、并发与恢复

问题：如何证明不会无限调用模型？

回答思路：服务端共享请求预算、每阶段最多一次格式纠正、Revision 最多一次、无瞬态自动重试、总/单步超时；实际尝试计数而非只数成功。最坏预算要包含引用单元扩展，本轮 30 次预检因 C2 未严格界定而停止，后来另获授权冻结，不隐藏这个事实。

追问：用户说预算无限就不需要限制吗？答：仍需要结构上界、时间预算和停止条件；授权放宽费用不意味着可以改协议或无限重跑。证据：冻结计划、`model_adapter/runtime.py`、`harness/contracts.py`。

问题：取消为什么还要等待服务确认？

回答思路：远端调用已发送与底层线程都未必可物理取消，页面只申请取消，Harness 合作式检查，保存有效部分。资源关闭前排空，不能把 `async task` 被取消误认作工作线程结束。

问题：进程崩溃后怎么处理任务？

回答思路：SQLite 检查点保存事件与对象，重启未完成任务 `interrupted`，不自动重发；已完成结果与反馈保留，同库 `ProcessLease` 限制多实例。代价是用户需要手动决定新运行，不能承诺 `exactly-once` 远端调用。

问题：POST 超时如何避免重复付费？

回答思路：客户端锁定，不自动重试；显示状态未知，查询 `run_id`/列表核实。当前不是跨系统幂等协议的普遍证明，网络恢复仍需用户监督；不能拿“按钮置灰”声称所有分布式重试风险都解决。

16.4 深入：指标与真实失败

问题：428 个测试说明准确率很高吗？

回答思路：不说明；它验证程序契约与行为，真实语义只有有限构造/资料案例。分开组件、全闭环、结构完成与目标正确。举例 `schema12` 合法 `supported` 可能因上游 `answer_scope` 分类错误而漏检技术事实。

问题：Recall、完整依据和回答正确率有什么关系？

回答思路：Recall 是已标候选池分母，必要组合表示若干互补资料是否齐全，回答正确率需要对生成内容另行标注。unknown 保留名次，undefined 的指标写有效 `n`，不能删除未知项优化排名。

问题：为什么没有采用 Dense 或 reranker？

回答思路：代码可选实现与默认采用不同，固定实验显示局部改善未稳定提高完整依据，reranker 有组合退步。当前保留 BM25 可追踪基线；不宣称技术路线永远优劣。追问可沿报告核查配置哈希、候选池、截断审计和分母。

问题：说一个你能核查的失败和修复。

回答思路：可以选择模板根结构冲突、跨 `claim` 工具引用或 `field_path` 投影。按输入→响应→失败字段→原因→修复→验证→限制说明。若尚未亲自参与，不编造个人贡献；表达为“项目记录显示，我可以解释和复现这一机制”。

16.5 高阶：诚实说明尚未解决的问题

问题：双审是否能消除幻觉？

回答思路：不能；职责独立但共享提取和提供方模型，错误相关。typed bases 限制可接受结构，不证明语义理解。人工复核和失败归档保留，未提供安全认证。

问题：现在可以微调吗？

回答思路：未实施训练管线；先核实人工标签与来源权限、拆分任务和问题族，再冻结独立评估与采用/停止条件。用户反馈来源必须保留，不能未经审查当专家标签。

问题：这次真实 Revision 是否验收成功？

回答思路：服务内链路与持久化验证成功，模型结果仍 review_required；5 supported/1 insufficient、工程检查未全评估、一次格式纠正被归档。足以说明本机原型的这个链路已跑通，不能外推到所有电力问题。

面试准备应先独立走一条 run，再用上述问题练习两分钟回答和五分钟追问。好的回答包含机制、一个真实例子、代码/归档入口和限制；不需要堆模型名称或夸大效果。

16.6 为什么没有使用LangChain

回答思路：当前直接Python协议、dataclass、适配器和受控Harness已经满足固定流程；已有严格ID/版本/typed-basis校验、预算和observer需要明确控制，引入通用框架会增加映射与迁移成本。当前依赖和调用路径没有LangChain，不是先使用再宣称卸载。该取舍说明项目规模与既有工程复用，未做框架性能对照，也不主张LangChain不适合其他系统。

追问“以后会不会用”：只有明确新需求且能保持契约、预算、回查与失败隔离时再评估，不能为使用框架重建第二套Harness。证据是assembly/runtime及依赖清单，不是虚构一个未做的benchmark。

16.7 受控工作流和自主Agent

当前阶段、工具、输入身份、最大修订及停止条件由程序定义。模型在阶段内判断支持关系、提取或改写，却不能自由增加目标、无限调用、替换数据库或自行批准结果。自主Agent通常允许模型选择更多行动与路径；项目没有将这种自治作为已实现能力。

追问“双审并行是否自主”：并发只是调度方式，仍是固定的两个review任务。角色名字不是自治程度。共享主张、同一提供方模型意味着错误相关，独立职责不自动等于独立统计样本。

16.8 async、线程和取消

async协程在await处让出事件循环，并不让同步SQLite或CPU代码自动并行。当前Retriever用单工作线程持有只读连接，避免阻塞事件循环及跨线程连接混用。asyncio.shield保护底层future：调用方取消等待时，线程任务可能仍在执行；active未结束前拒绝新工作，服务关闭先drain。

双审create_task/gather可以并发等待网络，但cancel()是协作信号。远端已接收请求未必撤回，线程没有通用安全强杀。追问应说明耗时边界、部分保存和资源归还，而不是承诺“取消瞬间没有费用”。

16.9 SQLite WAL和单进程限制

WAL把更新追加到日志，读取可保持快照；它不意味着多个写事务同时自由写。RunStore用短BEGIN IMMEDIATE事务保护event、snapshot与object一起保存，timeout=2；长模型调用发生在事务外。写入失败回滚并转StorageError，服务停止后续相关工作。

单worker与ProcessLease是当前应用队列/存储拥有者的约束，不是SQLite只能被一个进程读取。若直接开多个uvicorn worker，每个有自己的活动槽和内存队列，会破坏“一个活动运行”语义；WAL解决不了调度分裂。未来多进程需要单独的协调设计，本轮没有实现。

16.10 客户端锁不是服务端幂等

posting/uncertainPost仅约束当前页面；两标签页、HTTP客户端或刷新后仍可各自POST。服务每次有效提交生成新run_id，当前没有按幂等键在服务端去重并返回同一已存在任务的协议。所以按钮锁不能证明exactly-once，也不能覆盖“服务器已接受但响应丢失”的情形。

当前策略是不自动重POST，状态未知时核对列表/已有run_id，再人工决定。未来若设计幂等键，需定义请求指纹、原子登记、冲突与保留期限；即使如此远端模型请求的物理一次性还需单独分析。本轮只是解释限制，不新增幂等功能。

17. 代码阅读任务与证据索引

17.1 可独立完成的阅读任务

任务一：从 `backend/assembly.py` 画出 `real` 与 `synthetic_fixture` 的共同组件和不同依赖，确认真实事实审核显式 `schema12`。验收标准是能指出哪个字段决定当前版本，而不是凭模块文件名推断。

任务二：选真实 v2 的一个 `supported` 与一个 `insufficient finding`，写出 `answer version`、`claim`、`typed basis`、`Evidence` 和工具身份。验收标准是每一步都能通过保存对象回查，不把范围锚点误写成技术事实依据。

任务三：读 `LimitedRepairPolicy.decide`，找出执行问题、可修复发现、修订次数之间的先后关系。解释为什么缺工程前提仍可做一次有限文本修订，又为什么最终仍要求人工复核。

任务四：读 `evaluation/supervised_retrieval.py`，构造一个前三名含 `unknown` 的排名，手算 `Hit/MRR` 与一个两成员必要组是否完整。不要运行真实检索或模型；目标是理解分母与排序，避免误报。

任务五：读页面 `fetch` 包装、提交锁和 `poll` 终止条件。画出 `POST` 超时、`GET` 断网、取消确认三个状态。说明哪个操作需要用户手动决定，哪个状态不等于任务不存在。

任务六：读 `store` 检查点与 `recovery`，解释事件、快照和不可变对象的作用。用离线测试入口理解恢复，不删除现有数据库，也不为了实验重发历史真实运行。

17.2 当前材料的权威顺序

材料	用途	使用注意
当前源代码与真实装配	解释已实现行为	旧模块存在不代表启用
冻结计划/ <code>manifest</code>	解释某次实际运行版本	临时预算不替代默认配置
原响应、 <code>usage</code> 与失败矩阵	核查实际模型行为	私有归档不上传全文
当前 <code>prototype/handoff</code>	单一使用入口与状态	历史段落保留当时状态
历史实验报告	解释取舍、失败与演进	不拼接不同版本当一次成功
本手册	学习、面试与阅读路线	不是新实验或安全证书

17.3 公开代码和说明入口

- `docs/prototype-v0.1.md`：启动、令牌、操作与已知限制。
- `docs/local-review-service-v1.md`、`docs/local-review-ui-v1.md`：应用服务与界面说明。
- `docs/design-decisions.md`：重要采用与不采用决策。

- docs/documentation-index.md: 完整素材路径索引。
- docs/knowledge-sources/manifest.json: 已获取来源、哈希与范围。
- docs/review-reliability-v2.md、docs/fact-rereview-v3.md: 真实失败和组件边界。
- docs/github-upload-troubleshooting.md: 本轮网络诊断与本机修复步骤。
- docs/handbook-diagrams-r1.md: 本手册图源与含义。

17.4 私有本机验证索引

data/runtime_local/v0.1-acceptance/reading-notes.md 与 revision-review.md 给出本轮验收结论和逐发现阅读; verification.json 给出测试、浏览器、usage 和版本; offline-tests-post-batch.txt 保存 428 项最终测试。

真实截图为 real-revision.jpg、real-feedback.jpg、real-restart.jpg 与 real-final-summary.jpg; 来源和恶意文本验证另有客户端与演示材料。它们证明实际浏览器查看过对应内容, 不证明所有浏览器组合或所有语义都正确。

Git 基线审计在 data/runtime_local/github-baseline/, 记录候选、暂存、历史 blob 与安全网络诊断; PDF 排版核验在 data/runtime_local/handbook-r1/, 包含构建摘要、页数与渲染检查。忽略目录不随 GitHub 迁移, 需要用户自行保管。

17.5 交付边界

既有归档已真实验证两个 API 模式、一次服务内有限修订、重提取/双审、Evidence 与工具回查、版本反馈和重启保留。队列满、各种异常、危险文本与部分恢复还有演示/离线证据, 不能统一归为真实模型验收。

剩余限制包括目标分类与 fidelity 混淆、有限样例覆盖、PDF 视觉未逐页核对、开发领域规则、缺工程前提和没有仿真。它们允许人工监督的本机辅助使用, 阻断自动批准与工程安全认证。GitHub 上传截至 2026-10-04 前轮记录未完成; 本轮未查询最新网络状态, 本地可回退代码基线已存在。

本手册交付可编辑 Markdown、图源和 PDF。后续若代码、知识或协议发生变化, 应独立版本化并更新对应证据; 不要覆盖历史失败, 也不因这次文档完成自动开始下一轮付费验证。

18. 五段关键代码：输入、输出和异常边界

这些片段从本轮实际工作区源码自动摘录，仅去除公共缩进，没有改写、伪造省略号或替换为理想实现。PDF中的长行优先在空格/逗号等边界换行，续行用 > 标记（仅为排版，不是源码）；复制运行应使用Markdown或原文件。片段不是独立脚本，依赖所在函数的已定义对象；行号与摘录SHA在本轮核验记录中。

18.1 真实装配：组件注入而非第二套流程

```
harness=OfflineHarness(EvidenceGenerationAgent(model,settings,diagnostic_dir=diag,schema_version=3),
    ModelEvidenceVerificationAgent(model,settings,diagnostic_dir=diag,schema_version=12),
    ModelPowerDomainReviewAgent(domain_model,settings,diagnostic_dir=diag,protocol_version=4),
    ModelRevisionAgent(model,settings,diagnostic_dir=diag,protocol_version=2),
    ModelClaimExtractor(model,settings,diagnostic_dir=diag,typed_components=True,protocol_version=7),
    policy=LimitedRepairPolicy(),retriever=retriever,unit_tool=UnitConversionTool(version='scalar-si-conversion-v2'),
    > observer=observer)
return Bundle(harness,resources)
```

输入：已建立的model/domain_model、固定索引Retriever、settings、诊断目录、observer。输出：含现有Harness及资源的Bundle。Generation=3、事实schema12、Domain=4、Revision=2、Extractor=7均显式，LimitedRepairPolicy是原政策。

外围try若构造失败会关闭已创建资源并抛ConfigurationError；没有自动假组件回退。片段中的protocol_version属于各组件本地契约，不能拿数字不同推断版本“落后”。Bundle不意味着run已执行，只是构造完成。

18.2 并行审核：相同冻结目标，独立产物

```
reviewers = [asyncio.create_task(job) for job in (
    review("evidence_verification", self.verification, v_input, merge_evidence(v_evidence, original_evidence), True,
    > v_retrieval_issue),
    review("power_domain_review", self.domain_review, d_input, d_evidence, False, d_retrieval_issue),
)]
try:
    (verification, v_issue), (domain, d_issue) = await asyncio.gather(*reviewers)
except BaseException:
    for reviewer in reviewers:
        reviewer.cancel()
    await asyncio.gather(*reviewers,return_exceptions=True)
    raise
```

输入：v_input/d_input绑定同一answer/claims，各自允许Evidence和检索问题。输出：(verification,v_issue)、(domain,d_issue)两组，review包装会把可报告阶段问题转成issue；后续代码保留有效peer与检查完整性。

BaseException分支取消所有reviewer，再gather(return_exceptions=True)收尾后重新抛出；不吞取消信号。协程并发不保证提供方请求物理取消，也不让两个模型判断统计独立。

18.3 政策：修订机会不等于放行

```
def decide(self, verification, domain_review, budget, revision_round):
    base=super().decide(verification, domain_review, budget, revision_round)
    if verification.execution_issues or domain_review.execution_issues:
        return base
    actionable=any(f.status in (VerificationStatus.CONTRADICTED, VerificationStatus.INSUFFICIENT_EVIDENCE)
        for f in verification.findings) or any(f.check_status=="warning" for f in domain_review.findings)
    actionable=actionable or any(c.status=="warning" for c in verification.consistency_checks)
    if actionable and revision_round < min(1, budget.max_revision_rounds):
        return AuditDecision(DecisionKind.REVISE, (
            > "One bounded repair of observed issues; incomplete checks remain unresolved; full re-review required",),
            "limited-repair-policy-v1", base.unresolved_finding_ids)
    return AuditDecision(DecisionKind.REVIEW_REQUIRED,
        ("Limited reviews completed or stopped; unresolved findings and unperformed engineering analysis remain; no s
        > afety certification",)+base.reasons,
        "limited-repair-policy-v1", base.unresolved_finding_ids)
```

输入：两个审核结果、服务预算、revision_round。输出：AuditDecision，不调用模型。base已考虑执行/工程完整性；执行问题提前返回。actionable观察矛盾、证据不足、领域或程序warning；min(1,预算)使有限修订不超过一次。达到限制或没有修订必要时仍review_required，保留base原因和未解决ID。

这段代码没有自动重跑与“修到pass”；模型格式是否合法由前面校验器负责。预算耗尽的执行问题不能通过调政策伪造完整审核。

18.4 检查点：观察事件进入一个短事务

```
def checkpoint(self, rid, snapshot):
    v=wire(snapshot); event=v['event']
    with self.tx():
        ordinal=self.db.execute('SELECT COUNT(*) FROM events WHERE run_id=?',(rid,)).fetchone()[0]+1
        self.db.execute('INSERT INTO events VALUES (?,?,?,?,?)',(rid, event['event_id'], ordinal, dumps(event), dumps(v.get(
            > 'stage_output'))))
        self.db.execute('UPDATE runs SET snapshot=?, harness_state=? WHERE id=?',(dumps(v), v['state'], rid))
        # Bind domain finding IDs to this frozen answer; domain findings already have explicit bindings.
        self.index(rid, v)
        if v.get('stage_output') and event['component']=='evidence_verification':
            answer=v['stage_output']; aid=answer['answer_id']; version=answer['answer_version']
            for f in answer['findings']:
                self.index(rid, dict(f, answer_id=aid, answer_version=version))
```

输入：Harness发出的snapshot及已登记rid；wire转结构化投影，event必须有身份。输出为持久化副作用，没有新模型判断。事件ordinal、snapshot/harness_state、对象索引在同一tx内提交；事实finding补上冻结answer/version。

应用层实际接线：`bundle=self.factory.create(rid, lambda snapshot: self.store.checkpoint(rid, snapshot))`。因此数据库由ApplicationService/RunStore持有，Harness只调用observer。tx的SQLite异常回滚并转StorageError，不保证失败的检查点已保存；observer失败使流程停止，之前有效事务保留。

18.5 页面提交：当前页面锁与未知请求

```

$('submit-form').addEventListener('submit', async e => {
  e.preventDefault(); if (posting || uncertainPost || !token || profile === null) return;
  const mode = $('mode').value; const requirements = $('requirements').value.split("\n").map(s => s.trim()).filter(Boolean);
  if (!($('question').value.trim() || mode === 'assess_existing' && !($('existing').value.trim()
    > )) || requirements.length > 10 || requirements.some(s => s.length > 4000)) { tell('请检查问题、已有回答及回答要求长度。',
    > true); return; }
  const payload = { mode, question: $('question').value.trim(), user_context: $('context').value,
    > answer_requirements: requirements };
  if (mode === 'assess_existing') payload.existing_answer = $('existing').value;
  if (!($('reference').value.trim() || payload.references = [{ label: $('reference-label').value || '用户参考（未核实）', text: $('
    > reference').value }]);
  posting = true; controls(); tell('正在提交一次任务，请勿重复提交。'); let accepted;
  try { const before = profile; await health(); if (profile !== before) { tell('服务模式已变化，请核对页面模式标识后再次手动提交。',
    > true); } else accepted = await api('/runs', payload); } catch (err) {
    if (!(err instanceof ApiError)) { uncertainPost = true; tell(errorText(
      > err) + ' 提交已锁定，请重新连接并核对运行列表后再决定。', true); } else tell(errorText(err), true);
  } finally { posting = false; controls(); }
  if (accepted) { $('run-id').value = accepted.run_id; tell('任务已接受：${accepted.run_id}'); await selectRun(accepted.run_id);
    > try { await history(); } catch (err) { tell('任务已接受：${accepted.run_id}，运行列表暂时无法查询。` + errorText(err), true); }
  });

```

输入：页面字段、内存令牌和当前profile。输出：唯一这次POST的accepted.run_id，或明确错误/未知状态。posting在await之前设为true，阻止同页面重复点击；health发现模式变化时本次不POST。网络异常将uncertainPost锁定，ApiError则显示确定HTTP错误。finally清posting，但uncertainPost仍防止自动再发。

accepted后立即保存run_id并选择结果视图；历史列表GET失败不等于任务失败。未确认accepted时，服务器可能已创建任务，故先核查历史而非自动重试。此逻辑没有服务端幂等键，不能阻止另一页面或客户端提交。

18.6 当前版本和复核结果

本轮当前代码HEAD仍为3d5e0cd842a1039731aafb209fb5444bd1905622，master，仅一个提交；运行源码与HEAD逐文件一致。已有文档工作区修改来自前轮，不称本轮业务改动。五段摘录均回查实际代码并记录行号及SHA；日常默认40请求、96014历史异常与未修复的引用成本边界分开记录。

旧31页Markdown/PDF及旧图源/构建器完整保留，r1另存。2026-10-04前轮网络状态不替代本轮核查：本轮不查询远端、不调用服务、不提交或推送、不重跑历史测试和实验。小型公式算例为教学手算，其计算检查不是检索实验。